

Entrega Semanal 3 — Esbozo de Preliminares

Noel Pérez Calvo

12 de marzo de 2026

Preliminares: qué se va a decir de cada elemento

- Ecuaciones no lineales
 - definición de ecuación no lineal (ecuación donde la incógnita aparece con grado mayor que 1 o dentro de funciones no lineales)
 - diferencia con ecuaciones lineales
 - ecuación paramétrica: $F(x; \alpha_1, \dots, \alpha_n) = 0$, donde x es la incógnita y los α_i son parámetros
 - el concepto de raíz o cero de una ecuación
 - que una ecuación puede tener múltiples raíces reales
- Expresiones analíticas
 - qué es una expresión analítica (fórmula cerrada)
 - diferencia entre solución numérica y solución analítica
 - ejemplo: la fórmula general cuadrática $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$ como expresión analítica de las raíces de $ax^2 + bx + c = 0$
 - teorema de Abel–Ruffini: no existe fórmula general para polinomios de grado ≥ 5 , lo cual motiva un enfoque computacional
- Resolución numérica
 - qué es resolver numéricamente una ecuación (obtener un valor decimal aproximado)
 - concepto de método iterativo para encontrar raíces (Newton–Raphson como ejemplo clásico)
 - necesidad de un punto inicial (initial guess) y posibilidad de no convergencia
 - que en este trabajo se usa como paso intermedio: primero se resuelve numéricamente para muchos parámetros y luego se descubre la fórmula
- Rama de soluciones
 - cuando una ecuación tiene k raíces, se ordenan de menor a mayor
 - la i -ésima raíz más pequeña para cada combinación de parámetros forma la rama i
 - cada rama se trata como un problema de regresión independiente
- SymPy
 - biblioteca de Python para matemática simbólica
 - permite representar y manipular expresiones algebraicas de forma exacta
 - funciones `solve` (solución simbólica exacta) y `nsolve` (solución numérica)
 - función `sympify` para convertir texto a expresiones simbólicas
- Parser simbólico

- programa que convierte una cadena de texto en una estructura simbólica manipulable
 - en el contexto del trabajo: recibe la ecuación como string y produce un objeto SymPy
 - detecta automáticamente variables e incógnitas
- Grid de parámetros y producto cartesiano
 - discretización de un rango continuo en puntos equiespaciados
 - producto cartesiano: todas las combinaciones posibles de valores de cada parámetro
 - ejemplo: si $a \in \{1, 2, 3\}$ y $b \in \{4, 5\}$, el producto cartesiano es $\{(1, 4), (1, 5), (2, 4), (2, 5), (3, 4), (3, 5)\}$
 - Regresión simbólica
 - técnica de aprendizaje automático que busca la expresión matemática que mejor se ajusta a un conjunto de datos
 - a diferencia de la regresión clásica (que ajusta coeficientes de un modelo fijo), la regresión simbólica descubre la estructura de la fórmula
 - las expresiones se representan como árboles de expresiones
 - Programación genética
 - metaheurística de optimización inspirada en la evolución biológica
 - los individuos son programas (en este caso, árboles de expresiones matemáticas)
 - operaciones: mutación (modificar un nodo del árbol), crossover (intercambiar subárboles entre dos individuos), selección
 - es el mecanismo que usa PySR internamente para buscar expresiones
 - Población y ciclo evolutivo
 - población: conjunto de individuos (expresiones candidatas) que evolucionan simultáneamente
 - ciclo evolutivo: una iteración de selección, crossover, mutación y reemplazo
 - modelo de islas: múltiples poblaciones independientes con migración periódica entre ellas para mantener diversidad
 - Tournament selection y presión selectiva
 - tournament selection: se eligen k individuos al azar y el mejor pasa a la siguiente generación
 - presión selectiva: qué tan agresivamente se favorece a los mejores individuos
 - mayor tamaño de torneo $\Rightarrow$ mayor presión $\Rightarrow$ convergencia más rápida pero menor diversidad
 - en el trabajo se redujo la presión selectiva para evitar convergencia prematura
 - Diversidad de la población y convergencia prematura
 - diversidad: variedad genética (estructural) entre los individuos de la población
 - convergencia prematura: cuando la población pierde diversidad demasiado rápido y se queda atrapada en un óptimo local
 - parámetros que afectan la diversidad: tamaño de torneo, tasa de migración, probabilidad de crossover
 - Crossover
 - operador genético que combina material de dos individuos padres para crear descendencia
 - en programación genética: intercambio de subárboles entre dos árboles de expresiones
 - la tasa de crossover controla el balance entre exploración y explotación
 - Exploración vs. explotación

- exploración: buscar en regiones nuevas del espacio de soluciones
 - explotación: refinar soluciones ya encontradas
 - un buen algoritmo evolutivo necesita equilibrio entre ambas
- Hall of fame y frente de Pareto
 - hall of fame en PySR: conjunto de las mejores expresiones encontradas a lo largo de la búsqueda
 - frente de Pareto: conjunto de soluciones no dominadas en el compromiso complejidad vs. precisión
 - una expresión está en el frente si no hay otra que sea simultáneamente más simple y más precisa
 - Ecuaciones candidatas
 - cada expresión en el hall of fame es una ecuación candidata
 - en el trabajo se evalúan todas las candidatas (no solo la “mejor”) porque la que PySR considera mejor por balance complejidad/error no siempre es la que cubre más puntos
 - Operadores matemáticos seguros (`safe_pow`)
 - problema: durante la evolución genética, expresiones intermedias pueden producir NaN (raíz cuadrada de negativo, por ejemplo)
 - solución: definir $\text{safe_pow}(x, y) = \text{sign}(x) \cdot |x|^y$
 - permite descubrir raíces de cualquier orden sin errores numéricos
 - PySR tiene un mecanismo llamado bumper para esto, pero en la práctica eliminaba expresiones con raíces antes de que pudieran componerse
 - MSE (error cuadrático medio)
 - función de pérdida: $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - mide la diferencia promedio al cuadrado entre valores reales y predichos
 - se eligió MSE estándar porque los datos generados numéricamente no tienen ruido
 - Ruido en datos
 - datos con ruido: contienen errores aleatorios (propios de mediciones experimentales)
 - datos sin ruido: valores exactos (como los generados numéricamente en este trabajo)
 - la ausencia de ruido permite usar MSE sin regularización adicional
 - Batching (mini-batches)
 - técnica de dividir el dataset en subconjuntos pequeños para entrenar
 - reduce el consumo de memoria RAM
 - en el trabajo se usan mini-batches de 200 puntos
 - Expresión piecewise
 - función definida por partes: distintas fórmulas aplican en distintas regiones del dominio
 - surge cuando la regresión simbólica iterativa encuentra varias expresiones para una misma rama, cada una cubriendo una región distinta del espacio de parámetros
 - se ensamblan automáticamente detectando las fronteras de cada región
 - Benchmark
 - conjunto de problemas de prueba estandarizados para evaluar un sistema
 - en el trabajo: 43 casos de prueba (10 lineales, 14 cuadráticos, 6 cúbicos, 4 cuárticos, 1 quíntico, 8 especiales)

- cada caso tiene: la ecuación, las raíces esperadas y métricas automáticas
 - relación con SRBench (benchmark estándar de regresión simbólica, NeurIPS 2022)
- Bases de Gröbner
 - herramienta del álgebra computacional para manipular ideales polinómicos
 - análogas a la eliminación gaussiana, pero para sistemas de ecuaciones polinómicas no lineales
 - permiten decidir si un polinomio pertenece a un ideal dado (problema de pertenencia)
 - se calculan mediante el algoritmo de Buchberger
 - en el trabajo: se usan para verificar algebraicamente que las expresiones descubiertas son raíces exactas de la ecuación original
 - Bibliotecas de regresión simbólica (PySR, gplearn)
 - PySR: biblioteca basada en Julia con interfaz Python, usa modelo de islas y exploración multi-población
 - gplearn: biblioteca de Python pura, basada en scikit-learn
 - se seleccionó PySR por su rendimiento superior en benchmarks y su backend compilado en Julia
 - Julia
 - lenguaje de programación de alto rendimiento para computación científica
 - PySR lo usa como backend para que la búsqueda evolutiva sea eficiente
 - compilación JIT (just-in-time) permite velocidad comparable a C
 - Estado del arte
 - revisión de la literatura científica existente sobre un tema
 - en el trabajo: se revisaron 30 artículos sobre regresión simbólica, búsqueda de raíces y álgebra computacional
 - permite identificar qué se ha hecho, qué falta y cómo se posiciona el trabajo